

Identificação de Áreas Queimadas

Estudo sobre a Vegetação do Cerrado com Imagens Multitemporais do Sensor WFI e Aprendizado de Máquina

Antonio Gomes de Oliveira Junior

INPE 2025

Dr. Pedro Andrade e Dr. Thales Körting

Introdução

- O Cerrado é um bioma com alto risco de queimadas.
- O mapeamento eficiente de áreas queimadas é essencial para a preservação ambiental.

Introdução



Mapa dos hotspots de biodiversidade do mundo



fonte: Jenkins e Pimm 2006

Incêndios no Cerrado



Nacional

Incêndios devastam 88 milhões de hectares no Cerrado em 39 anos, diz estudo

Pesquisa revela que área queimada equivale a 43% de toda a extensão do bioma e supera o território de países como Chile e Turquia

João Rosa, da CNN, Brasília

11/09/24 às 03:35 | Atualizado 11/09/24 às 09:50



Introdução

- O sensoriamento remoto orbital permite a observação contínua da vegetação.
- O uso de modelos de aprendizado profundo pode melhorar a classificação de áreas queimadas.

Hipótese

Hipótese: É possível classificar com precisão áreas queimadas usando séries temporais de índices espectrais derivados de imagens do sensor WFI, mesmo sem acesso à banda (**shortwave infrared**) SWIR.

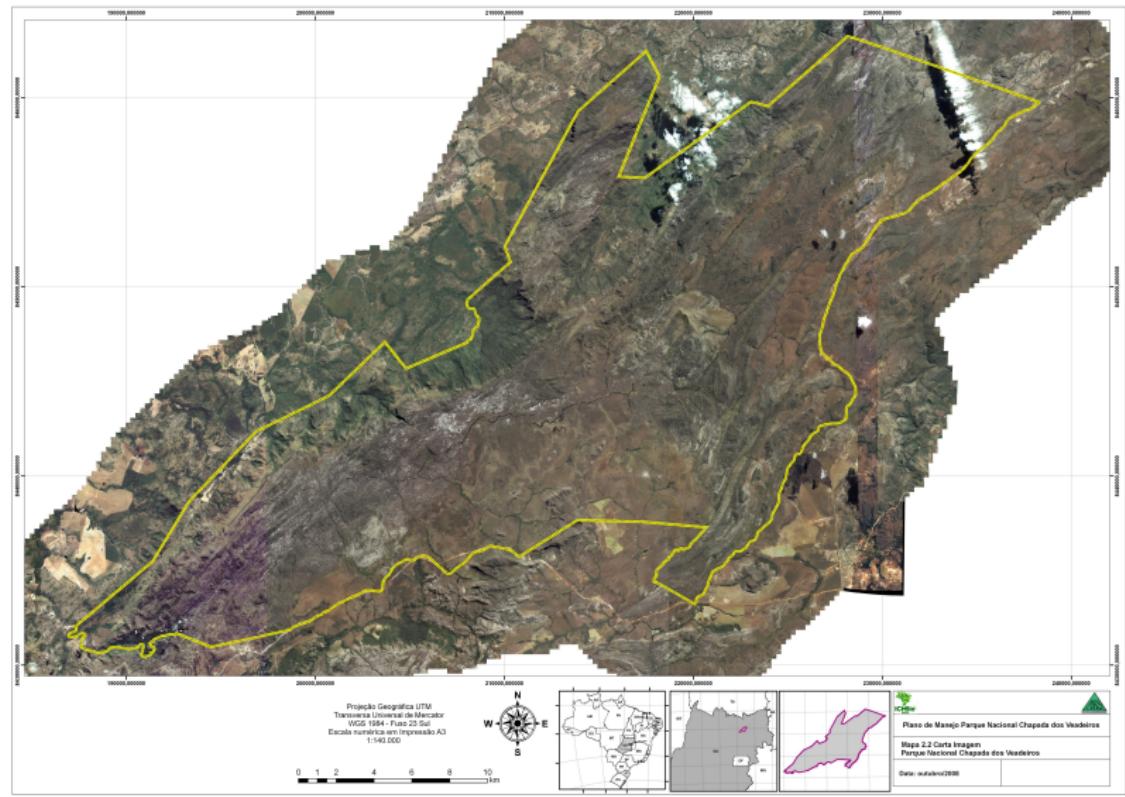
Objetivo Geral

Desenvolver modelos de aprendizado profundo capazes de classificar áreas queimadas a partir de séries temporais multiespectrais do sensor WFI, explorando a alta frequência temporal de aquisição das imagens para aprimorar a detecção e monitoramento das queimadas.

Objetivos Específicos

- Testar diferentes índices espectrais que possam ser trabalhados usando as bandas do WFI: Bandas do Espectro Visível e Near Infrared (NIR)
- Avaliar a eficácia de modelos LSTM e CNN para classificação de áreas queimadas
- Comparar os resultados com um modelo de referência (Random Forest)
- Analisar as métricas de desempenho, como acurácia, recall e IoU

Área de Estudo (Fonte: Instituto Chico Mendes)

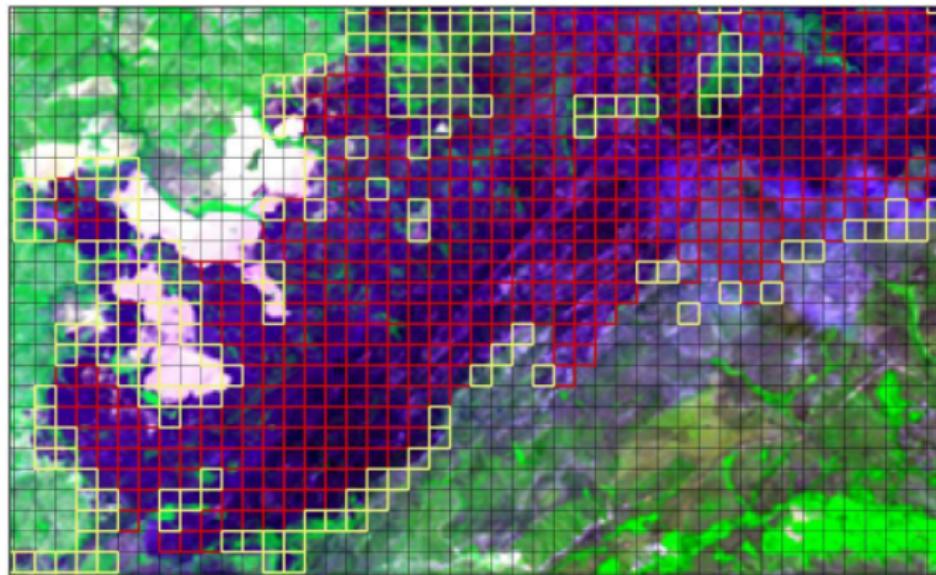


Satélites com sensor WFI disponíveis no Brasil

Satélite	Lançamento	Altura da Órbita	Resolução Temporal (WFI)	Resolução Espacial
CBERS-4	07/12/2014	778 km	5 dias	64 metros
CBERS-4A	20/12/2019	629 km	5 dias	55-60 metros
AMAZONIA-1	28/02/2021	752 km	5 dias	64 metros

Todos operam com o sensor WFI (sem banda SWIR)

Base de Dados e Área de Estudo



Burned areas

■ **Totally burned**

■ **Partially burned**

□ **Unburned**

Características Principais

- Parque Nacional da Chapada dos Veadeiros (GO)
- 235 imagens livres de nuvens entre 2020 e 2022 (CBERS-4, 4A e AMAZONIA-1) (Oliveira e Korting 2025)
- **Total de células:** 38.957 (grade 163x239)
- **Resolução espacial:** 500m × 500m por célula
- **Atualização:** Versão 2 (4 Junho 2025)

Índices Espectrais Derivados

Índice	Bandas	Fórmula Simplificada
NDVI (Normalized Difference Vegetation Index)	NIR, Red	$\frac{NIR - Red}{NIR + Red}$
EVI (Enhanced Vegetation Index)	NIR, Red, Blue	$\frac{2.5(NIR - Red)}{NIR + 6 \cdot Red - 7.5 \cdot Blue + 1}$
NDWI (Normalized Difference Water Index)	NIR, Green	$\frac{NIR - Green}{NIR + Green}$
BAI (Burned Area Index)	Red, NIR	$\frac{1}{(NIR - 0.06)^2 + (Red - 0.1)^2}$
GEMI (Global Environmental Monitoring Index)	Red, NIR	$n = \frac{2(NIR^2 - Red^2) + 1.5 \cdot NIR + 0.5 \cdot Red}{NIR + Red + 0.5}$ $GEMI = n \cdot (1 - 0.25 \cdot n) - \frac{Red - 0.125}{1 - Red}$

Índices Espectrais Derivados

Índice	Aplicação na Detecção de Queimadas
NDVI	Deteta o vigor da vegetação valores baixos indicam vegetação degradada ou queimada.
EVI	Mais sensível que o NDVI reduz efeitos de saturação e ruído atmosférico.
NDWI	Indica o teor de umidade áreas queimadas tendem a apresentar valores baixos.
BAI	Desenvolvido para realçar áreas queimadas, baseado na resposta espectral do carvão.
GEMI	Menos afetado por efeitos atmosféricos útil em regiões com sombra e cobertura de nuvens.

Conjunto de Dados: Visão Geral e Estrutura Espectral

Dados Espectrais e Índices

Tipo de Dado	Prefixo Colunas	Índices
Índice (ID)	id	[0]
Banda Azul (Blue)	a....	[1:1095]
Banda Verde (Green)	b....	[1096:2190]
Banda Vermelha (Red)	c....	[2191:3285]
IVP (NIR)	d....	[3286:4380]
BAI	e....	[4381:5475]
EVI	f....	[5476:6570]
GEMI	g....	[6571:7665]
NDVI	h....	[7666:8760]
NDWI	i....	[8761:9855]

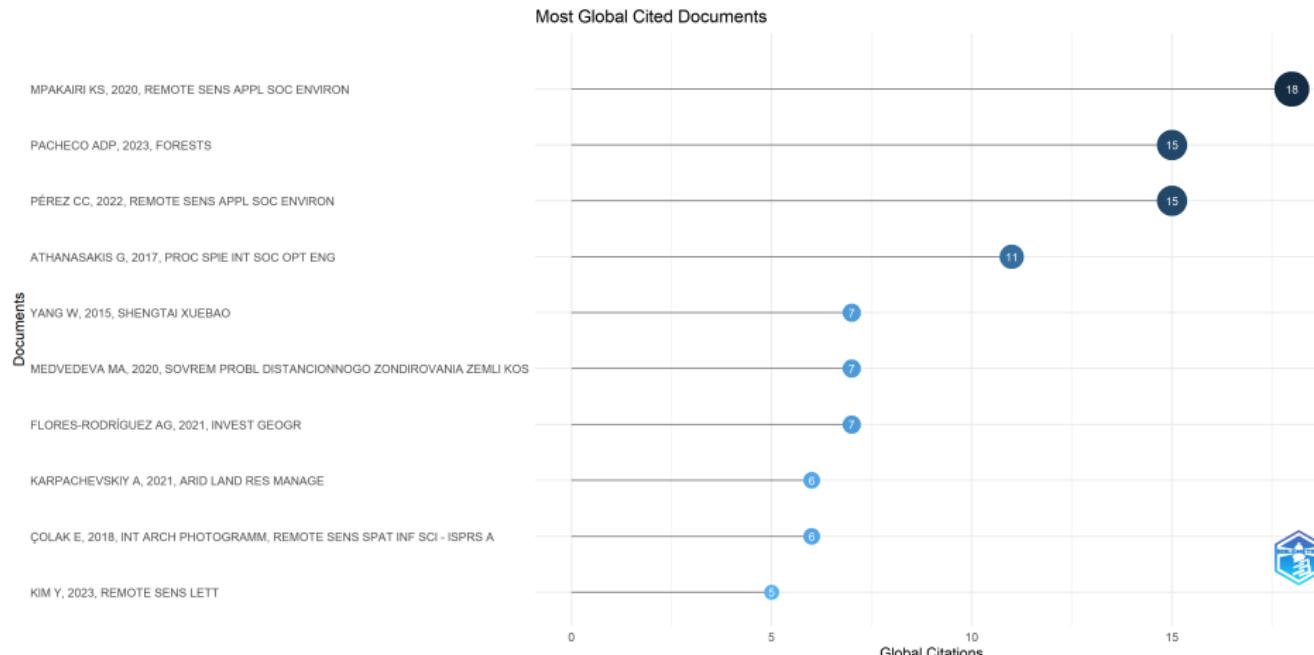
Notas

- Cada banda/índice contém 1095 colunas (3 anos × 365 dias)
- Estrutura total: 9.861 colunas de dados espectrais
- Prefixos indicam o tipo de dado (a=Blue, b=Green, etc.)

Informações Espaciais

- **Arquivos de referência:** Shapefile e GeoPackage
- **Colunas:**
 - 'index' (correspondente ao ID do dataset)
 - 'geometry' (polígonos das células)
- **Sistema de referência:** WGS84 (EPSG:4326)
- **Correspondência:** Relação 1:1 entre features espaciais e linhas do CSV

Revisão Scopus: Top 10 Artigos de classificação de queimadas na savana com índices RGB e NIR



TESTING THE UTILITY OF BLUE SPECTRAL REGION IN BURNED AREA MAPPING

Testing the utility of the blue spectral region in burned area mapping: Insights from savanna wildfires

Kudzai Shaun Mpakairi  , Shamiso Lynnet Kadzungwe, Henry Ndaimani

Show more 

 Add to Mendeley  Share  Cite

<https://doi.org/10.1016/j.rse.2020.100365> 

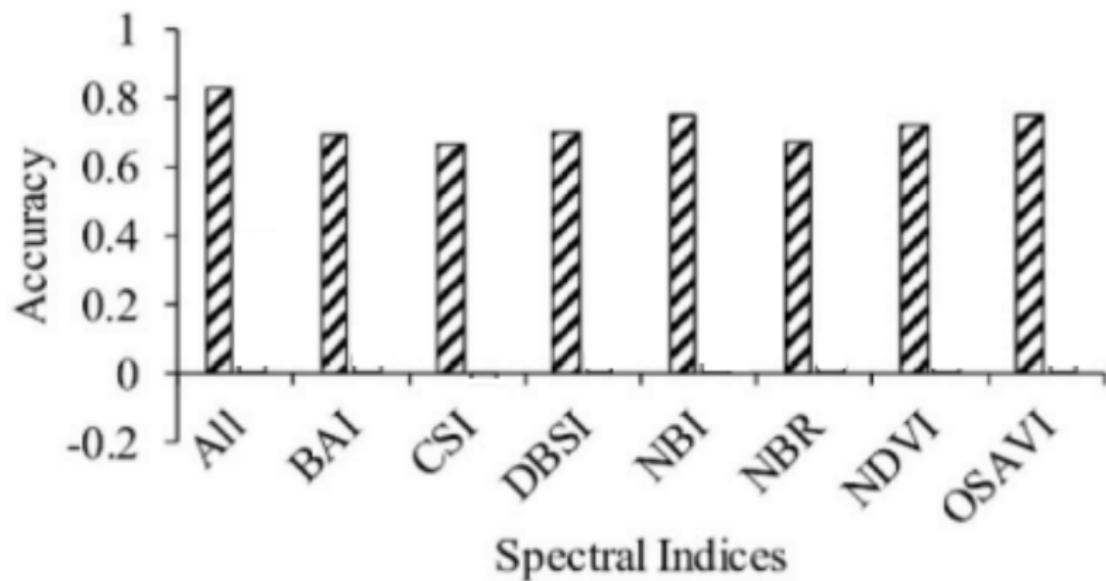
Get rights and content 

Abstract

Monitoring ecosystem events such as wildfires with remote sensing is fundamental to natural resources management. However, precisely delineating burned areas with remote sensing remains a challenge for post-fire ecological assessment. Burned area mapping methods with spectral indices are affected by several interferences such as soil background, water surfaces and atmospheric effects. In this study, we test the applicability of a normalized difference spectral index with the shortwave infrared and blue spectral bands in accurately mapping burned areas. The spectral index was tested in two study sites and compared to six spectral indices commonly used in burned area mapping. Random forest (RF), a machine learning algorithm, was used to classify the spectral indices and map burned areas. Although the True Skill Statistic (TSS) was relatively low, we found out that the Optimized Soil Adjusted Vegetation Index (OSAVI) and Normalized Burned Index (NBI) performed better than all the other spectral indices considered in the two study sites. The Burned Area Index (BAI) was the third highest performing spectral index. OSAVI and NBI performed well in the study sites plausibly because they were adjusted for soil effects and the blue spectral band was included to account for atmospheric effects. Our results indicate the need to adjust spectral indices



TESTING THE UTILITY OF BLUE SPECTRAL REGION IN BURNED AREA MAPPING



BURNED AREA DETECTION IN THE BRAZILIAN AMAZON USING SPECTRAL INDICES AND GEOBIA



Revista Brasileira de Cartografia

ISSN 1808-0936 | <https://doi.org/10.14393/revbrascartogr>

Sociedade Brasileira de Cartografia, Geodésia, Fotogrametria e Sensoriamento Remoto



Burned Area Detection in the Brazilian Amazon using Spectral Indices and GEOBIA

Detecção de Áreas Queimadas na Amazônia Brasileira usando Índices Espectrais e GEOBIA

Thales Vaz Penha¹, Thales Sehn Körting², Leila Maria Garcia Fonseca³, Celso Henrique Leite Silva Junior⁴, Mikhaela Aloisia Jéssie Santos Pletsch⁵, Liana Oighenstein Anderson⁶ e Fabiano Morelli⁷

Abstract: Mapping refined burned areas (BA) in the Brazilian Amazon is still a challenge. The main difficulty of BA detection in large areas is the presence of cloud cover and water bodies. The use of different data sources of medium spatial resolution satellite images can provide a higher availability of cloud-free images. Besides that, it may decrease the uncertainties associated with coarse spatial resolution data (>250m), which can under or overestimate BA and hinder the detection of small BA patches (<0.1km²). In this study, we propose an innovative methodology based on spectral indices and geographic object-based image analysis (GEOBIA), using medium spatial resolution images to improve BA detection in the Brazilian Amazon region. Firstly, we assessed the performance of nine spectral indices in two study areas, derived from Landsat-8 OLI and Sentinel-2A MSI data to identify the most suitable index for BA detection in this region. Then, we refined this data through the GEOBIA-based model. The results showed that the Burned Area Index (BAI) was the most suitable index for BA mapping (M index >1.5) for both sensors. Our model allowed detecting more than 80% of small BA and also presented high Dice coefficient values (~0.70) with low omission and commission errors (0.22 and 0.32, respectively). Such combined approach corresponds to a novel contribution to the BA detection in the Brazilian Amazon region and for enhancing the operational product generation.

Keywords: Fires mapping. Tropical forest. Landsat-8 OLI. Sentinel-2A MSI.

BURNED AREA DETECTION IN THE BRAZILIAN AMAZON USING SPECTRAL INDICES AND GEOBIA

Os autores propuseram uma abordagem de detecção de áreas queimadas na Amazônia usando índices espectrais combinados com análise orientada a objetos (GEOBIA).

- Foram utilizados dados Landsat-8 OLI e Sentinel-2A
- O índice BAI se destacou como o mais eficaz
- Segmentação em objetos melhorou a detecção, especialmente para áreas pequenas (menor que 1 km²)
- A metodologia é robusta em ambientes com alta cobertura de nuvens.

BURNED AREA MAPPING IN THE BRAZILIAN SAVANA USING A ONE CLASS SUPPORT VECTOR MACHINE



remote sensing



Article

Burned Area Mapping in the Brazilian Savanna Using a One-Class Support Vector Machine Trained by Active Fires

Allan A. Pereira ^{1,*}, José M. C. Pereira ^{2,†}, Renata Libonati ^{3,‡}, Duarte Oom ^{2,‡}, Alberto W. Setzer ^{4,†}, Fabiano Morelli ^{4,†}, Fausto Machado-Silva ^{3,‡} and Luis Marcelo Tavares de Carvalho ^{5,†}

Abstract: We used the Visible Infrared Imaging Radiometer Suite (VIIRS) active fire data (375 m spatial resolution) to automatically extract multispectral samples and train a One-Class Support Vector Machine for burned area mapping, and applied the resulting classification algorithm to 300-m spatial resolution imagery from the Project for On-Board Autonomy-Vegetation (PROBA-V). The active fire data were screened to prevent extraction of unrepresentative burned area samples and combined with surface reflectance bi-weekly composites to produce burned area maps. The procedure was applied over the Brazilian Cerrado savanna, validated with reference maps obtained from Landsat images and compared with the Collection 6 Moderate Resolution Imaging Spectrometer (MODIS) Burned Area product (MCD64A1). Results show that the algorithm developed improved the detection of small-sized scars and displayed results more similar to the reference data than MCD64A1. Unlike active fire-based region growing algorithms, the proposed approach allows for the detection and mapping of burn scars without active fires, thus eliminating a potential source of omission error. The burned area mapping approach presented here should facilitate the development of operational-automated burned area algorithms, and is very straightforward for implementation with other sensors.

Keywords: support vector machine one class; burned area; active fire; Cerrado; PROBA-V; VIIRS

BURNED AREA MAPPING IN THE BRAZILIAN SAVANA USING A ONE CLASS SUPPORT VECTOR MACHINE

Os autores propuseram o uso de Support Vector Machine com uma classe (OC-SVM) treinado com focos de calor para mapear áreas queimadas no Cerrado.

- Usaram imagens MODIS para validação por dados de referência. O OC-SVM teve resultados com melhor representatividade que os valores da base de dados de referencia (produto MCD64A1 do MODIS)
- Estratégia evita necessidade de grande base de dados rotulada
- Reduz a chance de erros de omissão se comparado a algoritmos de crescimento de região de fogos ativos.

Deep Learning Classification of Land Cover and Crop Types Using Remote Sensing Data

- Aplicaram CNNs em imagens Landsat
 - Classificaram uso da terra e tipos de culturas com alta acurácia
 - Mostraram que CNNs funcionam bem para classificação de uso da terra
- (Kussul et al. 2017)

Deep learning based multi-temporal crop classification

- Usaram LSTM com dados Landsat para classificar culturas agrícolas ao longo do tempo
 - LSTM superou SVM e Random Forest ao capturar padrões sazonais
 - Mostraram potencial de redes recorrentes
- (Zhong, Hu e Zhou 2019)

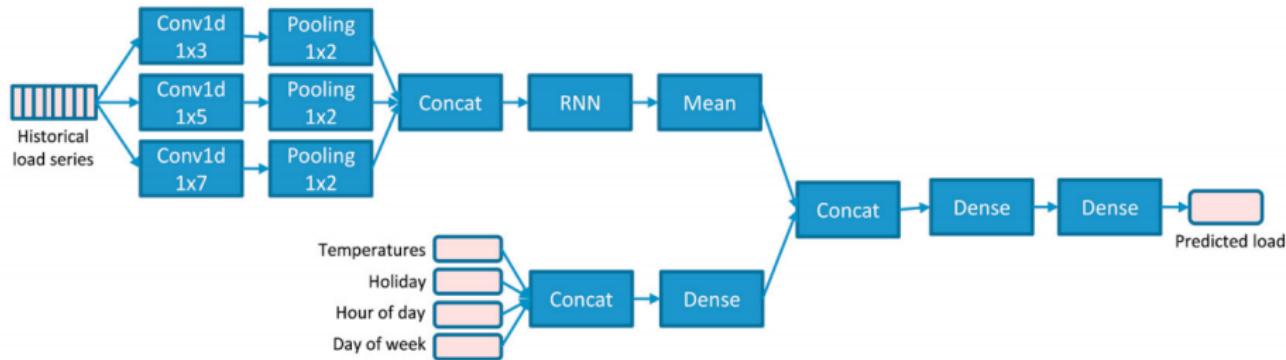
Load Forecasting via Deep Neural Networks

He (2017)

he2017 propôs uma **rede neural convolucional profunda** para previsão de consumo de energia de curto prazo, usando dados históricos de cidades do norte da China.

- **Abordagem:** múltiplas CNNs em paralelo para extração de características, seguidas por uma rede LSTM para previsão.
- **Ferramentas:** Keras (Deep Neural Network) e scikit-learn (Regressão Linear e SVM).
- **Resultados:** o modelo proposto obteve um MAPE cerca de 50% menor que a regressão linear.
- **Relevância para este trabalho:** a combinação **CNN + LSTM** pode ser adaptada para *classificação de áreas queimadas* a partir de séries temporais multiespectrais do sensor WFI, explorando a capacidade das CNNs para extração espacial e das LSTMs para dependências temporais.

Load Forecasting via Deep Neural Networks

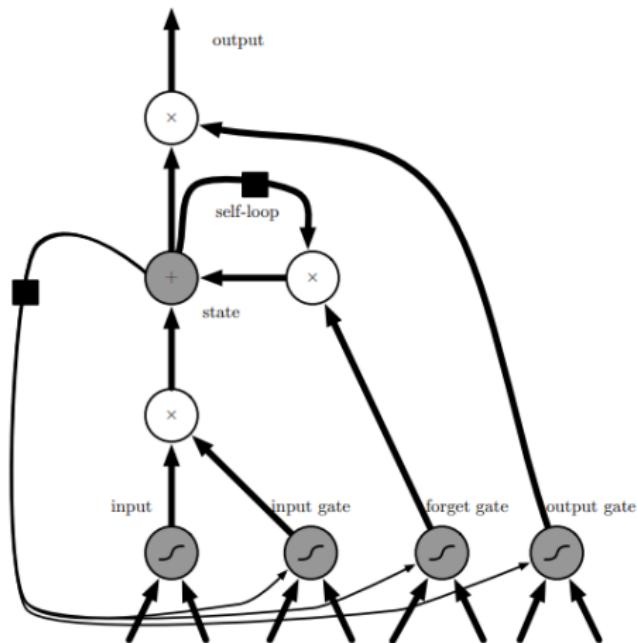


Evidências do Uso de Deep Learning

- Diversos trabalhos na literatura demonstram o sucesso de redes profundas (CNNs e LSTMs) aplicadas a dados de sensoriamento remoto
- Técnicas como LSTM e CNN foram aplicadas com sucesso para classificação de uso da terra, detecção de queimadas e mudanças sazonais

Ampliação da Revisão Bibliográfica

- Trabalhos relevantes já tratam de detecção de áreas queimadas no Cerrado e outros biomas (MapBiomas Fogo, MCD64A1 MODIS)
- **Limitação comum:** dependência da banda SWIR e dificuldade em capturar padrões temporais
- Este trabalho se diferencia ao explorar LSTM com dados WFI, buscando superar essas limitações

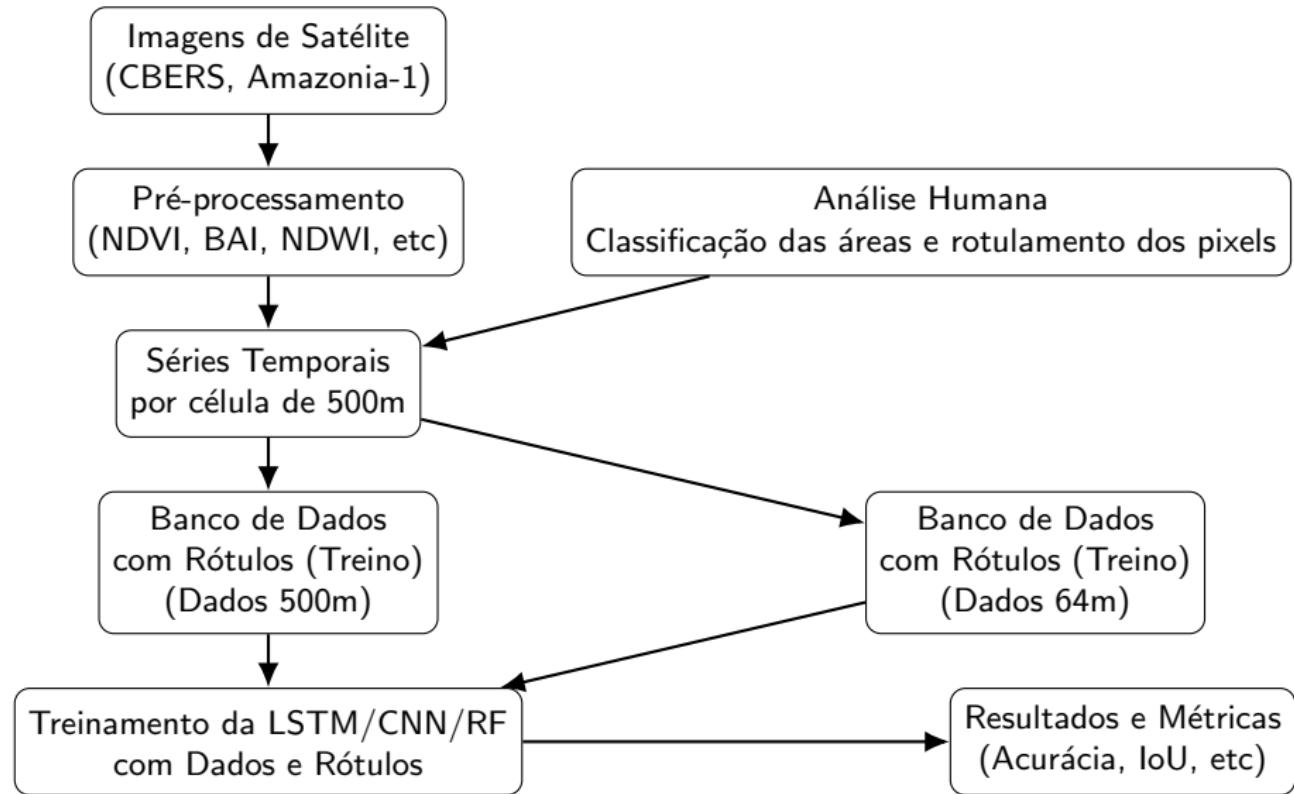


fonte: Deep learning: adaptive computation and machine learning
(YOSHUA, 2016)

Justificativa para uso de LSTM e CNN

- LSTM permite modelar a variação temporal dos índices espectrais, capturando padrões de ocorrência de fogo
- CNN explora a estrutura espacial das imagens (64x64), aproveitando padrões visuais e contextuais. Similar a forma que o cérebro interpreta a visão Dyck et al. 2021
- Uso combinado pode potencializar os resultados em comparação com métodos puramente baseados em índices
- Mesmo com resolução baixa, há evidências na literatura de sucesso com redes profundas aplicadas a sensoriamento remoto

Fluxograma do Projeto



Contribuições do Trabalho

- Utilização de dados do sensor WFI, de satélites brasileiros (CBERS-4, 4A e AMAZONIA-1), para classificação de áreas queimadas sem uso da banda SWIR
- Avaliação de modelos de aprendizado profundo (LSTM e CNN) com diferentes estratégias de entrada (temporal e espacial)
- Comparação sistemática com modelo baseline Random Forest

Cronograma de Atividades

ID	Descrição	Meses (2025–2026)											
		3	4	5	6	7	8	9	10	11	12	1	2
A	Revisão bibliográfica												
B	Pré-processamento do dataset												
C	Random Forest baseline												
D	Teste de modelos DL												
E	Escrita e submissão de artigo												
F	Escrita da dissertação												
G	Defesa da dissertação												

Referências I

-  Dyck, Leonard Elia van et al. (out. de 2021). "Comparing object recognition in humans and deep convolutional neural networks-an eye tracking study". *en. Em: Front. Neurosci.* 15, p. 750639.
-  Jenkins, Clinton e Stuart Pimm (jan. de 2006). "Definindo prioridades de conservação em um hotspot de biodiversidade global". *Em: Biologia da Conservação*, pp. 41–52.
-  Kussul, Nataliia et al. (2017). "Deep learning classification of land cover and crop types using remote sensing data". *Em: IEEE Geoscience and Remote Sensing Letters* 14.5, pp. 778–782. DOI: 10.1109/LGRS.2017.2681128.
-  Oliveira, Alisson Cleiton de e Thales Sehn Korting (fev. de 2025). *WFI data for mapping burned areas*. Versão V1. DOI: 10.57760/sciencedb.14040.

Referências II

-  Zhong, Lingxiao, Linhai Hu e Hongbo Zhou (2019). "Deep learning based multi-temporal crop classification". Em: *Remote Sensing of Environment* 221, pp. 430–443. DOI: 10.1016/j.rse.2018.11.032.